Calidad, warm starts y cotas

Seguimiento y ablación independientes de OMS

14 de octubre de 2026 — documento de investigación

Resultado. Hay una señal concreta para Budget-L2 en un modelo auténtico: evita objetivos pobres e informes de L2 contradichos. La ablación identifica un efecto de la representación final. No hay ventaja general frente a Base/IF1 y el envío v1.3.5 permanece separado y sin cambios.

Diseño prospectivo y entregas

48 asignaciones: los tres MIPLIB previamente seleccionados, semillas nuevas 31/47 y ocho tratamientos. Gurobi 13.0.2, cuatro hilos, gap 1 %, presolve y escalado interno automáticos salvo el control indicado. Frío: hasta 15 s; warm: hasta $1 + 14$ s MILP. Referencia global: 20 s, incluyendo selección, exportación, importación/cotejo, resolución, reparación, verificación y auditoría. Los factores diádicos existentes no se reajustan después de resultados.

Presupuestos $\delta_r = 10^{-4}\,\mathrm{máx}(1, |b_r|)$, cotas 10^{-4}, dominios enteros exactos; unidades algebraicas experimentales. Contratos para el punto crudo y comprobación separada del entero. No son tolerancias físicas operativas.

Tratamiento	Entregas	Suma s	Veto online	Cotas en pool
Cold-tight	6/6	71.189	1	1
Cold-IF1	6/6	77.904	0	0
Base-warm-tight	6/6	59.077	2	2
Base-warm-IF1	6/6	75.586	0	0
L2-warm-IF1	6/6	53.720	0	1
Budget-warm-IF1	4/6	63.252	0	0
Cold-tight-presolve-off	6/6	52.181	2	2
Witness-warm-tight	6/6	75.652	0	1

Las cuentas online y posteriores son por fase y se solapan. No se suman como fallos distintos. Denominador seis, incluidas abstenciones. La suma de tiempos no compara velocidades a calidad equivalente ni estima rendimiento poblacional.

Hubo 68 llamadas MILP y 46 entregas. Cinca se abstiene dos veces por 96 intervalos incompatibles. Se proporcionaron 28 Starts y los logs registran 27 cargas. No hubo errores o excesos de 20 s.

La preparación compartida se cronometró aparte. La persistencia final del seguimiento también; en ablación, el NPZ final se incluye sin medición separada. Los archivos auxiliares quedan en su etapa. El control Witness-warm tiene un testigo exacto previo cuya adquisición está excluida y declarada: es diagnóstico con información previa, no un algoritmo de velocidad nuevo. Los tres modelos no son familias nuevas ni una muestra representativa.

La reparación puede iniciar otra búsqueda, sin ventaja general

En control, warm-tight entrega 1.374590/1.400469 y warm-IF1 1.313721/1.313715, recuperando calidad frente al LP solo (antes 26.248128). Cold-IF1 entrega 1.265274/1.313755 y Cold-tight 1.322940/1.433450. Calentar no supera sistemáticamente a los controles robustos con igual asignación MILP.

Comparaciones por modelo/semilla: umbral descriptivo del 1 % del objetivo frío, además de una guarda numérica. No es significación estadística ni gap certificado.

Warm contra su control frío	Mejora > 1 %	Peor > 1 %	Sin dos entregas
Base-warm-tight	1	2	0
Base-warm-IF1	0	3	0
L2-warm-IF1	1	3	0
Budget-warm-IF1	0	3	2
Witness-warm-tight	2	1	0

Base-warm-IF1 no mejora más del 1 % en ningún par y empeora en tres. Witness-warm usa información previa y no es un control de velocidad equitativo.

Testigos y certificaciones incompatibles

Tres testigos exactos previos permitieron cinco vetos online. Los mejores testigos obtenidos después contradicen siete cotas y ocho informes de terminación al 1 %. Optimalidad continúa no verificada. Una cota no refutada no pasa a ser válida por esa ausencia de evidencia.

Los testigos completos verifican todas las filas, cotas y dominios. Los objetivos mostrados son 1.265277 en control y 7,547,811.68 en ta1-UUM. El checker coteja los MPS originales, incluyendo costos y dominios, bajo su interpretación binary64; no se mezclan modelos ni se usan puntos solo factibles dentro de tolerancias como testigos exactos.

En ta1-UUM, Base-warm-tight y presolve-off tienen cotas contradichas en ambas semillas; Cold-tight falla en 47. Witness-warm-tight/47 necesita el testigo mejor obtenido después. Un testigo previo demasiado caro no detecta todos los fallos. Desactivar presolve no elimina el problema y no se atribuye una causa interna específica al solver.

Consistencia del propio informe. Control/L2-warm-IF1/47 conserva etiqueta óptima, objetivo 5,643361 y cota −24,177882. Su log muestra gap 528,4306 %, frente al 1 % solicitado. Rechazar ese informe no requiere testigo externo. Se comprueban gap relativo, absoluto y una guarda; no se penaliza TIME_LIMIT por no alcanzar el objetivo. Este caso también tiene un testigo mejor, pero su cota negativa no queda refutada por él.

Ablación del mecanismo: representación final e inicio

La señal en control motivó una selección posterior explícita: estudio de mecanismo, no confirmación independiente de generalización. Antes de nuevas llamadas se congelaron 14 asignaciones con semillas 59/71: tres controles en frío y el cruce 2×2 L2/Budget entre origen y destino. Se conservaron todos los resultados y no se añadieron coeficientes M artificiales.

Mismo modelo, presupuestos, factores, tolerancias $10^{-6}/10^{-5}$, presolve automático e IntegralityFocus 1 en la fase final. Límites $1 + 14$ s warm y 15 s frío. Cambiar representación conserva exactamente filas/RHS, objetivo y dominios; el Start se transmite en coordenadas originales verificadas.

Tratamiento	Costo 59	Costo 71	Ciclo 59/71 s	Fuente final V
Cold-Base-IF1	1.315834	1.391930	15.352/15.323	2/2
Cold-L2-IF1	2.815707	33.373658	0.301/0.336	2/2
Cold-Budget-IF1	1.313510	1.265136	15.330/15.301	2/2
Warm-L2-to-L2	2.815707	6.238235	0.625/0.540	2/2
Warm-L2-to-Budget	1.313510	1.315735	14.528/14.496	2/2
Warm-Budget-to-L2	3.068627	7.875892	0.643/0.674	2/2
Warm-Budget-to-Budget	1.313506	1.265132	14.675/14.539	2/2

Fuente final V: punto del solver tras redondear pasa todas las comprobaciones; las entregas finales pasan en los catorce casos gracias al filtro y reparación.

Los seis destinos L2 declaran terminación óptima, pero sus informes al 1 % son contradichos por testigos exactos. Cuatro presentan cota inferior imposible y los otros dos un gap interno incompatible. Los seis destinos Budget alcanzan el límite y no declaran óptimo; costos 1.265–1.316. No se certifica su óptimo ni se considera válida una cota solo por no refutarla.

Budget→L2 entrega 3.068627/7.875892: un mejor tipo de inicio no rescata la representación L2. L2→Budget entrega 1.313510/1.315735 y evita esos resultados. El efecto pertenece a la representación final dentro de esta configuración; no identifica una operación interna concreta del solver. Los cuatro pares tienen Starts con valores binary64 idénticos y la misma primera fase, comprobados por el checker; cambia la representación final.

En frío, Budget da 1.313510/1.265136 frente a L2 2.815707/33.373658. Base/IF1 da 1.315834/1.391930 y no tiene cotas contradichas. Evitar el falso cierre rápido requiere casi todo el tiempo, unos 15 s frente a menos de 1 s. Es calidad y fiabilidad recuperada, no aceleración. Un modelo y cuatro semillas acumuladas no prueban ventaja general sobre controles existentes.

Propiedades del controlador

Sea $V_\delta(y)$ la comprobación completa de filas/cotas dentro de sus presupuestos y dominios enteros exactos. Cada candidato entra en S_k solo si verifica V_δ. Las etapas no borran candidatos. Por inclusión,

$$S_k \subseteq S_{k+1} \quad \Longrightarrow \quad \min_{y \in S_{k+1}} c(y) \leq \min_{y \in S_k} c(y).$$

Todo punto devuelto verifica, y una fase que falla o entrega un objetivo peor no hace perder el punto anterior. El costo se calcula racionalmente sobre los valores binary64. Si no hay candidato, se abstiene. No se garantiza progreso estricto ni superar otra configuración o encontrar el óptimo global.

Para un testigo racional factible q, $U = c^\top q$ es una cota superior primal. Cualquier cota inferior válida satisface

$$B \leq z^* \leq U.$$

Por tanto $B > U$ contradice su validez. El checker requiere el mismo modelo y factibilidad exacta de todas las filas, cotas y dominios. Usa una guarda de $\max(10^{-6}, 8\,\mathrm{ulp}(B))$. Una conversión flotante puede fallar su presupuesto aunque el testigo racional sea válido; se verifica por separado. No hallar contradicción no certifica optimalidad y el gap de un punto fuente no se hereda después de repararlo.

El filtro adicional del informe comprueba

$$|C - B| > \max\{0{,}01|C|, 10^{-10}\} + \text{guarda}.$$

Solo descarta incompatibilidad con la terminación solicitada; no certifica factibilidad, cota dual u óptimo. Se aplica posteriormente y se declara como tal, sin cambiar el diseño ya ejecutado. Nueve tests cubren retención, dominios, importación, modelos distintos, testigos exactos sin entrega binary64, gap relativo/absoluto y ausencia de inferencias de optimalidad.

Decisión de alcance para OMS

Existe un resultado tangible: con presolve normal y un modelo auténtico, la proyección contractual evita objetivos pobres e informes L2 refutados. El cruce confirma un efecto de la representación final. Es una señal para discutir el uso verificable de representaciones exportadas.

Todavía no justifica una contribución general adicional: un solo modelo presenta el mecanismo, Base/IF1 sigue siendo competitivo, el contrato no gana en otros casos o se abstiene, y warm no aporta ventaja general. Se mantiene v1.3.5 sin cambios. Una redacción candidata acotada queda en `INCORPORACION_CANDIDATA.md`, sin afirmar que contratos certifiquen cotas, optimalidad o superioridad universal.

Evidencia, fuentes y reproducción

62 asignaciones nuevas, 90 llamadas MILP, 60 entregas verificadas y dos abstenciones contractuales. Los checkers independientes comprueban fuentes, puntos, retención, testigos, límites y vetos; no importan los runners o controladores ni llaman solvers. Hay 61 registros nuevos de testigos exactos; pueden repetir puntos y no se anuncian como soluciones únicas.

Los tres MPS originales se verifican con hashes de descarga. Coeficientes, RHS, sentidos, costos, cotas y dominios se cotejan contra la representación canónica binary64. Los certificados corresponden a ese modelo, no a los decimales racionales ideales del MPS. El adapter independiente admite las características presentes y rechaza otras.

Los protocolos, hashes, fuentes, exportaciones, Starts, puntos, tiempos, datos adversos y certificados se conservan. La preparación compartida del seguimiento y la ablación se mide aparte. Los testigos previos se obtuvieron en estudios anteriores; para cinca, un LP exacto adicional de desarrollo se guarda y queda fuera de las 62 asignaciones. No se anuncia su adquisición como gratuita en Witness-warm ni se llama online al pool posterior.

Replay sin licencia comercial. Desde la raíz del artefacto, Python y NumPy bastan para ambos checkers. Pytest ejecuta nueve tests. Regenerar el documento necesita Python; compilarlo requiere pdfLaTeX. Ejecutar nuevas optimizaciones sí necesita Gurobi/HiGHS/SoPlex con las dependencias declaradas. Los códigos y modelos congelados no se editan para reanudar experimentos.

```
python3 exploration/oms-quality-followup-20261014/independent_check.py
python3 exploration/oms-quality-followup-20261014/check_ablation.py
python3 exploration/oms-quality-followup-20261014/write_report.py
```

Originalidad. Warm starts, reparación exacta y certificación tienen antecedentes explícitos. No se reclama su idea general como nueva. Se investiga la interacción de precisión, representación, aceptación, calidad y trazabilidad, con controles fuertes y resultados adversos. Las propiedades del filtro y de retención son elementales y no se venden como teoremas novedosos.

Gurobi: Start y atributos de variables.
Gurobi: MIPGap, MIPGapAbs e IntegralityFocus.
Eifler y Gleixner: exact rational MIP (2021).
SoPlex: LP exacto y referencias.
MIPLIB: Numerics y modelos originales.
Gurobi: convenciones MPS, bounds e integrality markers.